

Poker Elinde Farklı Makine Öğrenmesi Tekniklerinin Performans Karşılaştırılması

Yunus KAVAKLI

Berkay TEKİN

Yusuf Buruç ADAKUL

Gazi Üniversitesi, Teknoloji Fakültesi, Bilgisayar Mühendisliği Bölümü, Ankara, Türkiye

**Anahtar
Kelimeler**
Poker Eli,
Makine
Öğrenmesi,
Sınıflandırma
Algoritmaları

Özet: Makine öğrenmesi desenler ve ilişkiler öğrenerek gelecekteki tahminleri daha doğru bir şekilde yapabilen algoritmaların kullanımını ifade eder. Bu algoritmalar, sınıflandırma, regresyon, kümeleme gibi birçok farklı görevi yerine getirerek, sağlık, finans ve oyun gibi çeşitli alanlarda önemli katkılar sağlar. Poker gibi stratejik oyunlar, oyuncuların kararlarının belirli bir mantığa dayandığı ve her hamlenin başka bir sonucu etkilediği karmaşık sistemlerdir. Bu tür oyunlarda, makine öğrenmesi teknikleri kullanılarak, oyuncuların karar alma süreçlerini anlamak ve daha iyi stratejiler geliştirmek mümkündür. Yapay zeka, bu stratejik düşünme tarzlarını öğrenerek daha insana benzer kararlar alabilir, bu da oyun stratejilerini optimize etmek için büyük bir fırsat sunar. Bu çalışmada, poker oyununa ait 1 milyon satırlık veri seti kullanılarak altı farklı makine öğrenmesi algoritması (Random Forest, Naive Bayes, Lojistik Regresyon, Lineer Regresyon, KNN, Karar Ağacı) ile sınıflandırma analizi yapılmıştır. Veri seti, oyuncuların yaptığı hamleler, kart kombinasyonları ve sonuçları hakkında bilgi sunarak, oyuncuların stratejilerini ve karar verme süreçlerini anlamak için önemli fırsatlar yaratmaktadır. Veri setinde 10 farklı sınıf bulunmaktadır, ancak bazı sınıflar daha nadir olduğu için örnek sayıları azdır. Bu nadirlik, modelin sınıflandırma başarısını etkileyebilir ve stratejik düşünmenin öğrenilmesinde zorluklara yol açabilir. Kullanılan algoritmalar, bu veri seti üzerinde farklı başarılarla sonuçlanmıştır. Random Forest, kullanılan diğer algoritmalar arasından en yüksek başarıyı elde eden model olmuştur. Random Forest, veri setindeki karmaşıklıkları en iyi şekilde yönetmiş ve 1 milyon satırlık test verisi ile %75 doğruluk oranına, 25 bin satırlık eğitim verisinin iyileştirilmesiyle (F-Score+SMOTE) ise %92 doğruluk oranına ulaşmıştır. Bu sonuç, Random Forest algoritmasının poker gibi stratejik oyunlarda, büyük veri setleriyle en etkili sınıflandırma modelini sunduğunu ortaya koymakta.

Keywords
Poker Hand,
Machine
Learning,
Classification
Algorithms

Abstract: Machine learning refers to the use of algorithms that can learn patterns and relationships to make more accurate predictions in the future. These algorithms perform a variety of tasks such as classification, regression, and clustering, contributing significantly to fields like healthcare, finance, and gaming. Strategic games like poker are complex systems in which players' decisions are based on specific logic, and each move can influence subsequent outcomes. In such games, machine learning techniques can be employed to understand players' decision-making processes and to develop better strategies. Artificial intelligence can learn these strategic thinking patterns and make more human-like decisions, offering a great opportunity to optimize game strategies. In this study, a classification analysis was conducted using a dataset of 1 million rows from a poker game, employing six different machine learning algorithms: Random Forest, Naive Bayes, Logistic Regression, Linear Regression, K-Nearest Neighbors (KNN), and Decision Tree. The dataset provides information about players' moves, card combinations, and outcomes, creating valuable opportunities to understand strategies and decision-making processes. The dataset includes 10 different classes; however, some of these classes are rare, resulting in fewer examples. This rarity can affect classification performance and pose challenges for learning strategic thinking. The algorithms produced varying levels of success on this dataset. Among them, the Random Forest algorithm achieved the highest performance. It managed the complexity of the dataset most effectively and reached an accuracy rate of 75% on a test dataset of 1 million rows. After improving a 25,000-row training dataset using F-Score and SMOTE, the accuracy increased to 92%. These results indicate that Random Forest provides the most effective classification model for strategic games like poker, especially when working with large datasets.

1. Giriş (Introduction):

Poker, dünya çapında en popüler kart oyunlarından biri olup, oyuncuların ellerindeki kartları kullanarak çeşitli stratejilerle birbirleriyle yarıştığı bir şans ve beceri oyunudur. Oyuncular, eldeki kartları en yüksek kombinasyonla oynayarak rakiplerini yenmeye çalışırlar. Poker, özellikle beceri ve strateji gerektiren bir oyun olmasından ötürü, zeka oyunları arasında önemli bir yer tutar. Hem şans faktörü hem de psikolojik savaş unsurları, pokeri benzersiz kılar. Oyun, genellikle 2 ila 10 oyuncu arasında oynanır ve her oyuncuya bir dizi kart dağıtılır. Bu kartlar ve oyuncunun stratejileri, elde edilecek sonucun belirlenmesinde en önemli rolü oynar.

Pokerin birçok farklı versiyonu bulunmaktadır. Ancak en yaygın olarak oynanan türleri arasında Texas Hold'em, Omaha ve Seven Card Stud yer alır. Temelde pokerin nasıl oynandığını anlamak için birkaç önemli unsurdan bahsetmek gerekir:

Kart Dağıtımı: Oyunculara belirli sayıda kart dağıtılır (örneğin, Texas Hold'em'de her oyuncuya 2 kart, masadaki herkesle paylaşılan 5 ortak kart vardır).

Bahis Turları: Oyuncular, ellerindeki kartlara göre bahis yapar, pas geçer veya oyunu terk eder. Bu turlar, kart dağıtımından önce ve sonra birkaç kez yapılır.

Ellerin Değeri: Oyuncular, ellerindeki kartlarla belirli kombinasyonları oluştururlar. Her poker elinin belirli bir sıralaması vardır, örneğin:

- **Royal Flush:** Aynı türden 10, J, Q, K, A kartları
- **Straight Flush:** Aynı türden ardışık kartlar
- **Four of a Kind (Kare Dörtlü):** Aynı değerden dört kart
- **Full House:** Üçlü ve ikili kombinasyonu
- **Flush:** Aynı türden beş kart
- **Straight (Düz):** Ardışık beş kart
- **Three of a Kind:** Aynı değerden üç kart
- **Two Pair:** İki çift kart
- **One Pair:** Bir çift kart
- **High Card:** Diğer kombinasyonlardan daha düşük bir kart

Pokerdeki başarı, sadece şansa değil, aynı zamanda rakiplerin stratejilerinin doğru bir şekilde tahmin edilmesi ve doğru hamlelerin yapılması ile de ilgilidir. Bu nedenle poker, strateji, matematiksel analiz ve psikolojik tahminlerin harmanlandığı bir oyun olarak tanımlanabilir.

2. Çalışmanın Amacı ve Kapsamı:

Bu çalışmanın amacı, poker oyununda makine öğrenmesi ve yapay zeka kullanarak oyun stratejilerini analiz etmek ve sınıflandırma algoritmalarının başarısını karşılaştırmaktır. Veri seti, poker oyununda elde edilen kart kombinasyonları ve bahis stratejileri hakkında geniş bir bilgi sunarak, oyuncuların nasıl bir strateji izlediğini anlamaya yardımcı olacak verilere sahiptir. Çalışma, poker gibi strateji gerektiren oyunlarda, makine öğrenmesi algoritmalarının ne denli etkili olduğunu gözler önüne sermeyi amaçlamaktadır. Pokerde oyuncu stratejilerini tahmin edebilmek ve daha etkili oyun stratejileri geliştirebilmek için bu veriler üzerinde çeşitli makine öğrenmesi algoritmaları kullanılarak sınıflandırma yapılacaktır.

2.1. Veri Seti ve Yapay Zeka- Makine Öğrenmesi Açısından Faydaları:

Bu çalışmada kullanılan poker veri seti, oyuncuların hamleleri, kart kombinasyonları ve sonuçları gibi detaylı bilgileri içermektedir. Bu veri seti, strateji ve karar verme süreçlerini anlamak ve modellemek için önemli fırsatlar sunmaktadır. Veri setindeki 10 sınıf, poker oyununda çeşitli kart kombinasyonlarını ve bu kombinasyonların hangi stratejilerle daha başarılı olduğunu incelememizi sağlar. Bazı sınıfların nadir olması, modelin bu sınıfları doğru bir şekilde sınıflandırmada karşılaştığı zorlukları ortaya koymaktadır. Bu durum, veri dengesizliklerinin ve nadir sınıfların model başarısı üzerindeki etkisini gözler önüne serer. Yapay zeka, bu tür veri setlerinde daha doğru tahminler yapmak ve oyun stratejilerini doğru bir şekilde analiz etmek için kullanılacaktır.

2.2. Poker Hand Veri Seti ve Makine Öğrenmesi Uygulamaları:

Poker Hand veri seti, özellikle poker oyununda kart kombinasyonları ile ilgili tahminler yapmak amacıyla yaygın olarak kullanılan bir veri setidir. Bu veri seti, oyuncuların kart kombinasyonlarını ve oyun sonuçlarını içeren 10 sınıftan oluşan verilerden oluşmaktadır. Poker Hand veri seti, genellikle makine öğrenmesi algoritmalarının karşılaştırılması ve oyun stratejilerinin analiz edilmesi amacıyla kullanılmaktadır.

Birçok araştırma, Poker Hand veri setini kullanarak çeşitli makine öğrenmesi algoritmalarını karşılaştırmıştır. Örneğin, Bing et al. (2006), Poker Hand veri setini kullanarak, pokerdeki kart kombinasyonlarını sınıflandırmak amacıyla destek vektör

makinelere (SVM) ve karar ağaçlarını kullanmıştır. Bu çalışmada, kart kombinasyonları ve oyuncuların bahis stratejileri gibi faktörler incelenmiş, karar ağaçları ve SVM'nin performansları karşılaştırılmıştır. Ayrıca, Torgo (2010), Poker Hand veri setiyle yapılan bir çalışmada, Naive Bayes ve Karar Ağaçları algoritmalarını karşılaştırmış ve farklı modelleme tekniklerinin başarılarını analiz etmiştir. Bu çalışma, veri setinin poker oyununda kart kombinasyonlarının tahmin edilmesindeki başarısını ortaya koymuştur.

Breiman (2001) tarafından geliştirilen Random Forest algoritması, poker gibi karmaşık veri setlerinde büyük başarı göstermiştir. Poker Hand veri setinde, Random Forest algoritması, kart kombinasyonlarını sınıflandırırken yüksek doğruluk oranları elde etmiştir. Özellikle, Liaw & Wiener (2002) tarafından yapılan bir çalışmada, Poker Hand veri setini kullanarak Random Forest algoritmasının performansı detaylı bir şekilde incelenmiş ve diğer algoritmalarla karşılaştırılmıştır. Bu çalışma, Random Forest'in poker gibi oyunlarda sınıflandırma görevinde neden tercih edildiğini açıklamaktadır.

2.3. Poker Hand Veri Setinde Kullanılan Makine Öğrenmesi Algoritmaları

Poker Hand veri setini kullanan bir diğer önemli çalışma, Kruppa et al. (2006) tarafından yapılmıştır. Bu çalışmada, Poker Hand veri seti kullanılarak, Naive Bayes, KNN ve Lojistik Regresyon algoritmalarının poker oyunundaki başarıları karşılaştırılmıştır. Araştırmacılar, KNN algoritmasının pokerdeki bazı sınıfları doğru sınıflandırmakta zorluk yaşadığını, ancak Naive Bayes ve Lojistik Regresyon'un daha iyi sonuçlar verdiğini gözlemlemişlerdir. Bu sonuç, Poker Hand veri setinde her algoritmanın performansının, veri setinin yapısına göre değişebileceğini ortaya koymuştur.

2.4. Veri Seti Dengesizlikleri ve Yapay Zeka Uygulamaları

Poker Hand veri setindeki en önemli zorluklardan biri, sınıflar arasındaki dengesizliktir. Bazı kart kombinasyonları nadiren görülürken, diğerleri daha sık rastlanır. Bu durum, sınıflandırma algoritmalarının nadir sınıfları doğru bir şekilde tahmin etmesini zorlaştırmaktadır. SMOTE (Synthetic Minority Over-sampling Technique) gibi yöntemler, nadir sınıfların temsilini artırarak modelin genel doğruluğunu iyileştirmekte kullanılmaktadır. Chawla et al. (2002) tarafından geliştirilen SMOTE yöntemi, Poker Hand veri setindeki dengesizlikleri gidermekte etkili olmuştur. Bu yöntem, veri setinde daha az temsil edilen sınıfların daha iyi öğrenilmesini sağlayarak, algoritmaların performansını artırmıştır.

2.5. Çalışmanın Literatüre Katkısı

Bu çalışma, Poker Hand veri setinde kullanılan altı farklı makine öğrenmesi algoritmasının performanslarını karşılaştırarak, literatüre önemli bir katkı sağlamaktadır. Özellikle, Random Forest algoritmasının Poker Hand veri setindeki yüksek başarısını ve veri setindeki dengesizliklerin model başarısı üzerindeki etkilerini ele alması, mevcut literatüre yeni bir bakış açısı getirmektedir. Ayrıca, bu çalışma, veri dengesizliğinin ve nadir sınıfların doğru bir şekilde sınıflandırılmasındaki zorlukları ve bu zorlukların üstesinden gelmek için kullanılan iyileştirme yöntemlerini derinlemesine tartışmaktadır.

3. Materyal ve Yöntem

Poker Hand veri seti, poker gibi stratejik oyunlarda oyuncu stratejilerinin ve karar alma süreçlerinin modellenmesinde önemli bir kaynak sağlamaktadır. Yapılan çalışmalar, bu veri seti üzerinde kullanılan makine öğrenmesi algoritmalarının başarılarını karşılaştırarak, her algoritmanın güçlü ve zayıf yönlerini ortaya koymaktadır. Bu çalışma, özellikle Random Forest algoritmasının pokerdeki kart kombinasyonlarını doğru bir şekilde sınıflandırmada en etkili yöntem olduğunu göstermektedir. Ayrıca, poker oyunlarında veri dengesizliklerinin etkisi ve bu dengesizliklerin üstesinden gelmek için uygulanan iyileştirme yöntemleri de önemli bir araştırma konusu olmuştur.

Veri Seti ve Yöntemler (Dataset and Methods)

Veri Setinin Açıklaması

Bu çalışma, **Poker Hand** veri setini kullanarak poker oyununda stratejileri sınıflandırmak amacıyla gerçekleştirilmiştir. Poker Hand veri seti, UCI Machine Learning Repository'den alınmıştır ve poker oyununda elde edilen kart kombinasyonlarına dayalı olarak oyuncuların yaptığı hamlelerin analizini yapmaktadır. Veri seti, her biri 10 özellikten oluşan 1 milyon satırdan oluşmaktadır. Bu özellikler, oyuncuların elde edilen kart kombinasyonları, oyun sırasındaki hamleleri ve kazanan oyuncunun belirlenmesi gibi bilgileri içermektedir.

- **Özellikler (Features):** Veri setinde her örneğin 10 özellikten oluştuğu görülmektedir. Bu özellikler, oyuncuların kartlarını temsil eden 5 çift (S1, S2, S3, S4, S5 ve C1, C2, C3, C4, C5) olarak sunulmuştur. Burada "S" (Suits - renk) oyuncuların kartlarının rengini, "C" (Card - kart) ise kartların değerlerini temsil etmektedir. Bu özellikler pokerdeki her bir kartın türünü ve değerini belirtmektedir.
- **Sınıflar (Classes):** Veri seti, pokerdeki kart kombinasyonlarını sınıflandıran 10 farklı sınıftan oluşmaktadır. Bu sınıflar, pokerdeki tüm kart kombinasyonlarını temsil etmektedir ve oyuncunun elde ettiği kartlarına göre sınıflandırılmaktadır. Sınıflar şunlardır:

1. **Royal Flush**
2. **Straight Flush**
3. **Four of a Kind**
4. **Full House**
5. **Flush**
6. **Straight**
7. **Three of a Kind**
8. **Two Pair**
9. **One Pair**
10. **High Card**

- **Sınıf Sayısı (Number of Classes):** Veri seti 10 farklı sınıf içermektedir ve her sınıf belirli kart kombinasyonlarını temsil etmektedir. Bu sınıflar, pokerde kazanan ellerin türlerini belirlemek için kullanılır.
- **Örnek Sayısı (Number of Instances):** Veri seti toplamda 1 milyon satırdan oluşmaktadır. Her satır bir poker elini temsil eder ve bu satırlarda oyuncuların eldeki kartları ile ilgili bilgileri içerir. Bu büyük veri seti, poker gibi oyunlarda oyun stratejilerinin öğrenilmesi için büyük bir fırsat sunmaktadır.

Veri Setindeki Dengesizlikler ve Bu Dengesizliklerin Sebepleri

Poker Hand veri setinde belirgin bir sınıf dengesizliği bulunmaktadır. Özellikle bazı kart kombinasyonları (örneğin, **Royal Flush** veya **Straight Flush**) nadir görülürken, bazı kombinasyonlar (örneğin, **One Pair** ve **High Card**) daha sık rastlanan kombinasyonlardır. Bu sınıfların dengesizliği, makine öğrenmesi modellerinin bazı sınıfları doğru şekilde tahmin etmesini zorlaştırabilir.

- **Sınıf Dengesizlikleri:** Pokerdeki kart kombinasyonları, belirli bir düzende ve belirli kurallar altında dağılım gösterir. Bazı kombinasyonlar doğal olarak daha nadir olduğu için, bu sınıflar veri setinde daha az temsil edilir. Örneğin, **Royal Flush** gibi kombinasyonlar yalnızca belirli koşullar altında elde edilebilir ve bu da onların sınıf içinde düşük frekansa sahip olmasına neden olur. Öte yandan, **One Pair** gibi daha yaygın kombinasyonlar çok daha fazla örneğe sahiptir.
- **Dengesizliklerin Sebepleri:** Pokerde eldeki en güçlü eller nadir ortaya çıkar, bu da veri setindeki bazı sınıfların temsili- nin düşük olmasına yol açar. Örneğin, 5 kartın tamamının aynı türde olması (Flush) veya belirli bir düzende sıralanmış kartlar (Straight) daha nadir görülür. Bu, doğal olarak sınıflar arasında dengesizliğe yol açar.
- **Dengesizliklerin Etkileri:** Makine öğrenmesi algoritmaları, genellikle çoğunluk sınıfına yönelik daha fazla tahmin yapma eğilimindedir. Bu nedenle, nadir sınıfların doğru bir şekilde sınıflandırılması daha zor hale gelir. Özellikle doğru- luk oranı yüksek olan bir model, nadir sınıfları ihmal edebilir veya onları yanlış sınıflandırabilir. Bu tür dengesizlikler, modelin genel başarısını etkileyebilir ve performans iyileştirmeleri yapılmasını gerektirebilir. **SMOTE** (Synthetic Minority Over-sampling Technique) gibi teknikler, bu tür dengesizlikleri ele almak için kullanılabilir.

Makine Öğrenmesi Algoritmaları (Machine Learning Algorithms)

Bu çalışmada, poker veri setinde oyuncu stratejilerini sınıflandırmak ve kart kombinasyonlarını tahmin etmek amacıyla altı farklı makine öğrenmesi algoritması incelenmiştir. Her algoritma, poker gibi karmaşık ve büyük veri setlerinde farklı performans sergileme potansiyeline sahiptir. Aşağıda, her algoritmanın poker veri seti doğrultusunda nasıl çalıştığı ve elde edilen performans sonuçları açıklanmıştır.

1. Random Forest

- **Açıklama: Random Forest,** ensemble learning (topluluk öğrenme) yaklaşımını kullanarak çok sayıda karar ağacının birleşiminden oluşur. Her bir karar ağacı, eğitim veri setinin rastgele seçilmiş farklı alt kümeleri ve özellikler üzerinde eğitilir. Tahminler, tüm ağaçların sonuçlarının (sınıflandırma için çoğunluk oyu veya regresyon için ortalama) birleştirilmesiyle yapılır. Bu yöntem, karmaşık ilişkileri öğrenmede ve aşırı uyumu (overfitting) azaltmada güçlüdür.
- **Veri Seti Üzerindeki Performansı:** Poker veri seti üzerinde yapılan ilk denemelerde (varsayılan parametrelerle), Random Forest modeli %61.12 doğruluk (Accuracy) ve 0.5805 ağırlıklı F1 skoru (Weighted F1-score) elde etmiştir. Sınıflandırma raporu incelendiğinde, modelin özellikle sık görülen ilk iki sınıfta (0 ve 1) makul bir performans sergilediği (sırasıyla 0.71 ve 0.53 F1-skoru), ancak daha nadir sınıflarda (2'den 7'ye kadar) neredeyse hiç doğru tahmin yapamadığı (F1-skorları 0.01 veya 0.00) gözlemlenmiştir. Bu durum, veri setindeki sınıf dengesizliğinin model üzerindeki olumsuz etkisini göstermektedir.

- Veri dengesizliği iyileştirilmesi: **SMOTE** algoritması sınıflar arasındaki dengesizliği düzeltmek için kullanılan bir tekniktir. Bu yöntem azınlık sınıfındaki verilerin çoğaltılmasını sağlar. **SMOTE** dengesiz veri setlerinde **aşırı öğrenmeyi(overfitting)** engellemeye yardımcı olur ve modelin tüm sınıflar için iyi performans göstermesini sağlar. Bu yöntem modelin azınlık sınıflarını daha doğru öğrenmesini ve genelleme hatalarının azaltılmasını sağlar.

Yapılan optimizasyonlar ve muhtemelen veri dengeleme teknikleri sonrasında, Random Forest modelinin performansı belirgin şekilde iyileşmiştir. Güncellenmiş model, **%92.45** gibi çok yüksek bir doğruluk oranına ve 0.9254 ağırlıklı F1 skoruna ulaşmıştır. Sınıflandırma raporu, bu iyileşmenin tüm sınıflara yayıldığını göstermektedir; nadir sınıflar da dahil olmak üzere çoğu sınıf için precision, recall ve F1 skorları %95'in üzerine çıkmıştır. Bu sonuçlar, Random Forest'in optimize edildiğinde poker veri setindeki karmaşık örüntüleri ve sınıf dengesizliklerini başarıyla yönetebildiğini ve **en yüksek performansı** sergileyen algoritma olduğunu ortaya koymaktadır.

2. Naive Bayes

- Açıklama: **Naive Bayes**, Bayes teoremine dayanan olasılıksal bir sınıflandırma algoritmasıdır. Temel varsayımı, veri setindeki özelliklerin (özniteliklerin) birbirinden bağımsız olduğudur. Bu varsayım sayesinde, her bir özelliğin belirli bir sınıfa ait olma olasılığı ayrı ayrı hesaplanabilir ve bu olasılıklar birleştirilerek nihai sınıf tahmini yapılır. Özellikle metin sınıflandırma gibi görevlerde basitliği ve hızıyla öne çıkar.
- Veri Seti Üzerindeki Performansı: Poker veri seti üzerinde varsayılan ayarlarla çalıştırılan Naive Bayes algoritması, %51.02 doğruluk oranı elde etmiştir. Ancak sınıflandırma raporu ve karışıklık matrisi (Confusion Matrix) incelendiğinde, modelin tüm tahminleri en baskın sınıf olan '0' sınıfı olarak yaptığı görülmüştür. Diğer tüm sınıflar (1'den 7'ye kadar) için precision, recall ve F1 skorları 0.00 olarak ölçülmüştür. Bu durum, algoritmanın özellik bağımsızlığı varsayımının poker verisindeki ilişkileri yakalayamaması ve ciddi sınıf dengesizliğinden olumsuz etkilenmesi nedeniyle performansının son derece sınırlı kaldığını göstermektedir.
- Sınıf dengesizliği problemi, **upsampling (oversampling)** yöntemiyle çözülmüştür. Azınlık sınıflar çoğaltılarak veri seti dengelenmiştir. Azınlık sınıfların çoğaltılması, modelin her sınıfı doğru öğrenmesini sağlar. Dengesiz sınıflar model tarafından yeterince öğrenilmezse, yanlış sınıflandırma oranı yüksek olabilir. Bu iyileştirme, modelin sınıf dengesizliği nedeniyle oluşan hataları minimize eder ve doğruluğu artırır.

Veri setindeki sınıf dengesizliğini gidermek amacıyla yapılan dengeleme işlemi (örneğin, SMOTE gibi tekniklerle azınlık sınıflarının örnek sayısının artırılması veya çoğunluk sınıflarının azaltılması) sonrasında Naive Bayes modeli tekrar eğitilmiştir. Güncellenmiş modelin doğruluğu %54.29'a yükselmiştir. Daha da önemlisi, sınıflandırma raporu modelin artık farklı sınıfları tahmin etmeye çalıştığını göstermektedir. Özellikle 7, 8 ve 9. sınıflarda çok yüksek (0.98-0.99 F1-skoru), 4, 5 ve 6. sınıflarda orta düzeyde (0.45-0.52 F1-skoru) performans sergilemiştir. Ancak ilk dört sınıftaki (0-3) performansı hala düşüktür (0.11-0.26 F1-skoru). Bu sonuç, Naive Bayes'in veri dengeleme ile bir miktar iyileşme gösterse de, poker verisindeki karmaşık bağımlılıkları tam olarak modelleyemediğini ve doğruluğunun diğer gelişmiş modellere kıyasla sınırlı kaldığını teyit etmektedir.

3. Lojistik Regresyon

- Açıklama: **Lojistik Regresyon**, temel olarak ikili sınıflandırma problemleri için tasarlanmış bir istatistiksel modeldir. Sigmoid fonksiyonunu kullanarak bir örneğin belirli bir sınıfa ait olma olasılığını tahmin eder. Çoklu sınıf problemleri için ise "One-vs-Rest" (OvR) veya "Multinomial Lojistik Regresyon" gibi stratejilerle genişletilebilir. Bu çalışmada, çoklu sınıflı poker eli sınıflandırması için uyarlanmış bir versiyonu kullanılmıştır.
- Veri Seti Üzerindeki Performansı: Poker veri seti üzerinde Lojistik Regresyon modeli ile yapılan testlerde, hem varsayılan (default) hem de güncellenmiş (update) olarak belirtilen denemelerde %51.02'lik aynı doğruluk oranı elde edilmiştir. Sınıflandırma raporları ve karışıklık matrisleri de her iki durumda birebir aynıdır ve modelin tüm örnekleri baskın sınıf olan '0' sınıfı olarak tahmin ettiğini göstermektedir. Diğer tüm sınıflar için (1'den 7'ye kadar) precision, recall ve F1 skorları 0.00 olarak kalmıştır. Bu durum, Lojistik Regresyon'un, poker veri setindeki doğrusal olmayan ilişkileri ve sınıf dengesizliğini ele almakta yetersiz kaldığını ve yapılan güncellemelerin (eğer varsa) bu model özelinde bir performans artışı sağlamadığını göstermektedir. Modelin performansı, varsayılan Naive Bayes modeline benzer şekilde, baskın sınıf dışındaki örüntüleri öğrenememesi nedeniyle oldukça düşüktür.

4. Lineer Regresyon

- Açıklama: **Lineer Regresyon**, genellikle hedef değişkenin sürekli olduğu regresyon problemleri için kullanılan temel bir istatistiksel yöntemdir. Girdi özellikleri ile hedef değişken arasında doğrusal bir ilişki olduğunu varsayar. Sınıflandırma problemleri için doğrudan uygun olmasa da, bazen çıktı değerleri belirli eşiklere göre sınıflara atanarak veya çoklu sınıf durumları için uyarlamalar yapılarak kullanılabilir. Ancak temelindeki doğrusallık varsayımı, karmaşık sınıflandırma görevleri için genellikle bir kısıtlama oluşturur.

- Veri Seti Üzerindeki Performansı: Poker veri setinde sınıflandırma amacıyla uyarlanan Lineer Regresyon modeli, %48.28 gibi düşük bir doğruluk oranı sergilemiştir. Sınıflandırma raporu incelendiğinde, modelin '0' sınıfı için kısmen (0.63 F1-skoru) ve '1' sınıfı için çok zayıf (0.22 F1-skoru) bir performans gösterdiği, ancak diğer tüm nadir sınıflar (2'den 7'ye kadar) için hiçbir doğru tahminde bulunamadığı (F1 skorları 0.00) görülmüştür. Bu sonuçlar, Lineer Regresyon'un doğrusal varsayımının, poker eli kombinasyonları gibi karmaşık ve büyük ölçüde doğrusal olmayan ilişkiler içeren bir veri setinde sınıflandırma yapmak için yetersiz kaldığını açıkça göstermektedir.

5. K-Nearest Neighbors (KNN)

- Açıklama: **K-Nearest Neighbors (KNN)**, örnek bazlı öğrenme yapan ve parametrik olmayan bir sınıflandırma (ve regresyon) algoritmasıdır. Yeni bir veri noktasını sınıflandırmak için, eğitim setindeki mevcut veri noktalarından ona en yakın olan 'K' adet komşusunu bulur. Bu K komşunun ait olduğu sınıflar arasında en sık görülen sınıf, yeni veri noktasının sınıfı olarak atanır. Algoritmanın performansı, 'K' değeri ve kullanılan uzaklık metriğine (örneğin, Öklid uzaklığı) bağlıdır.
- Veri Seti Üzerindeki Performansı: Poker veri setinde varsayılan parametrelerle (K=5) çalıştırılan KNN algoritması, %50.64 doğruluk oranı elde etmiştir. Sınıflandırma raporu, modelin '0' ve '1' sınıflarında sırasıyla 0.59 ve 0.45 F1 skorları ile orta-düşük bir performans sergilediğini, ancak nadir sınıflarda (2'den 9'a kadar) çok düşük veya sıfır performans gösterdiğini ortaya koymuştur.
- **Oversampling** uygulaması ile azınlık sınıfındaki örnekler çoğaltılarak daha dengeli bir veri seti elde edilmiştir. Azınlık sınıfındaki örneklerin çoğaltılması, modelin doğru öğrenmesine katkı sağlayarak modelin daha doğru ve dengeli tahminler yapmasını sağlar. Bu optimizasyon özellikle veri setindeki azınlık sınıfların tahminleri için önemli bir uygulamadır.

Parametre optimizasyonu (örneğin, farklı K değerleri denenmesi) veya diğer iyileştirmeler sonrasında, KNN modelinin doğruluğu %55.74'e yükselmiştir. Güncellenmiş sınıflandırma raporu, '0' ve '1' sınıflarındaki performansın bir miktar iyileştiğini (F1 skorları 0.61 ve 0.54) ve modelin artık '2', '3', '4' ve '5' gibi bazı nadir sınıfları da (düşük F1 skorlarıyla da olsa) kısmen tanıyabildiğini göstermektedir. Ancak, en nadir sınıflardaki (6-9) performansı hala sıfıra yakındır. Bu sonuçlar, KNN'nin poker veri setinde Lojistik ve Lineer Regresyon'a göre biraz daha iyi performans gösterse de, özellikle büyük veri setlerinde hesaplama maliyetinin yüksek olması ve sınıf dengesizliklerinden olumsuz etkilenmesi nedeniyle doğruluğunun sınırlı kaldığını göstermektedir.

6. Karar Ağacı

- Açıklama: **Karar Ağacı**, veriyi sınıflandırmak için ağaç benzeri bir yapı kullanan denetimli öğrenme algoritmasıdır. Ağacın her bir iç düğümü bir özellik (öznitelik) üzerinde yapılan bir testi temsil eder, her bir dal testin sonucunu gösterir ve her bir yaprak düğümü bir sınıf etiketini temsil eder. Veri, kök düğümünden başlayarak özellik testleri boyunca dallanır ve sonunda bir yaprak düğümüne ulaşarak sınıflandırılır. Karar ağaçları, yorumlanabilirliği yüksek modellerdir.
- Veri Seti Üzerindeki Performansı: Poker veri seti üzerinde varsayılan ayarlarla eğitilen tek bir Karar Ağacı modeli, %48.84 doğruluk oranı elde etmiştir. Sınıflandırma raporu, modelin ilk dört sınıfta (0-3) düşük ila orta düzeyde F1 skorları (0.57, 0.47, 0.11, 0.07) sergilediğini, ancak daha nadir sınıflarda (4-9) performansının çok zayıf veya sıfır olduğunu göstermiştir. Bu durum, tek bir karar ağacının özellikle budama (pruning) gibi teknikler uygulanmadığında eğitim verisine aşırı uyum sağlama (overfitting) eğiliminde olabileceğini ve dengesiz verilerde genelleme performansının düşük kalabileceğini işaret etmektedir.
- **Oversampling** uygulaması ile azınlık sınıfındaki örnekler çoğaltılarak daha dengeli bir veri seti elde edilmiştir. Azınlık sınıfındaki örneklerin çoğaltılması, modelin doğru öğrenmesine katkı sağlayarak modelin daha doğru ve dengeli tahminler yapmasını sağlar. Bu optimizasyon özellikle veri setindeki azınlık sınıfların tahminleri için önemli bir uygulamadır.

Model parametrelerinin optimize edilmesi (örneğin, ağaç derinliğinin sınırlandırılması, minimum yaprak boyutu ayarı vb.) veya farklı kriterler kullanılması sonrasında, Karar Ağacı modelinin performansı önemli ölçüde artarak %67.07 doğruluğa ulaşmıştır. Güncellenmiş sınıflandırma raporu, bu iyileşmenin birçok sınıfa yansıdığını göstermektedir. Özellikle ilk dört sınıfın F1 skorları belirgin şekilde yükselmiş (0.69, 0.67, 0.58, 0.51) ve model artık 5, 6, 8 ve 9 gibi bazı nadir sınıfları da makul veya yüksek F1 skorlarıyla tanıyabilmektedir. Bu sonuç, optimize edilmiş bir Karar Ağacı'nın poker veri setinde varsayılan haline göre çok daha iyi bir performans sergileyebildiğini, ancak topluluk yöntemi olan Random Forest kadar yüksek bir doğruluğa ulaşamadığını göstermektedir.

4. Bulgular ve Tartışma

Bu çalışmada, poker eli veri seti üzerinde altı farklı makine öğrenmesi algoritmasının performansı, optimizasyon ve potansiyel veri dengeleme adımları sonrasında kapsamlı bir şekilde değerlendirilmiştir. Modellerin sınıflandırma başarısını ölçmek amacıyla doğruluk oranı (accuracy), ağırlıklı kesinlik (weighted precision), ağırlıklı hassasiyet (weighted recall) ve ağırlıklı F1-skoru gibi metrikler kullanılmıştır. Elde edilen optimize edilmiş sonuçlar, algoritmaların bu spesifik görevdeki etkinliklerini karşılaştırmak için temel alınmıştır. Elde edilen bulgular şu şekildedir:

- Rastgele Orman (Random Forest): %92.45 doğruluk ve 0.9254 ağırlıklı F1-skoru ile test edilen algoritmalar arasında açık ara en yüksek başarıyı göstermiştir. Bu sonuç, Rastgele Orman'ın topluluk yapısı sayesinde poker verisindeki karmaşık örüntüleri öğrenebildiğini ve sınıf dengesizliğine karşı diğer modellere göre daha dirençli olduğunu güçlü bir şekilde göstermektedir. Modelin yüksek kesinlik (%93) ve hassasiyet (%92) değerleri, farklı sınıfları dengeli bir şekilde tanıyabildiğini işaret etmektedir.
- Karar Ağacı (Decision Tree): Optimizasyon sonrasında %67.07 doğruluk ve 0.67 ağırlıklı F1-skoru ile ikinci en iyi performansı sergilemiştir. Varsayılan ayarlara kıyasla (önceki sonuçlarda görüldüğü gibi %48.84 doğruluk) önemli bir iyileşme kaydetmiş olsa da, tek bir ağacın performansı Rastgele Orman'ın oldukça gerisinde kalmıştır. Bu, tekil ağaçların genelleme yeteneğinin, özellikle karmaşık ve dengesiz veri setlerinde, topluluk modellerine kıyasla sınırlı olabileceğini göstermektedir.
- K-En Yakın Komşu (K-NN): %55.74 doğruluk ve 0.55 ağırlıklı F1-skoru ile orta-düşük bir performans göstermiştir. Optimizasyon ile bir miktar iyileşme (%50.64'ten %55.74'e) sağlanmış olsa da, veri setinin potansiyel yüksek boyutsallığı ve sınıf dengesizliği KNN'nin etkinliğini sınırlamış olabilir.
- Naive Bayes: Veri dengeleme sonrası %54.29 doğruluk ve 0.51 ağırlıklı F1-skoruna ulaşmıştır. Varsayılan modelin tüm tahminleri tek bir sınıfa yaptığı göz önüne alındığında (%51.02 doğruluk ama 0.34 F1-skoru), dengeleme işlemi modelin farklı sınıfları ayırt etme yeteneğini bir miktar artırmıştır. Ancak, özelliklerin bağımsız olduğu varsayımı, kartlar arasındaki doğal bağımlılıklar nedeniyle modelin genel başarısını ciddi şekilde kısıtlamıştır.
- Lojistik Regresyon: %51.02 doğruluk ve çok düşük bir ağırlıklı F1-skoru (0.34) ile zayıf bir performans sergilemiştir. Hem varsayılan hem de güncellenmiş sonuçların aynı olması ve F1 skurunun düşüklüğü, modelin poker verisindeki doğrusal olmayan yapıyı ve sınıf dengesizliğini ele almakta tamamen yetersiz kaldığını göstermektedir. Temelde sadece en baskın sınıfı tahmin edebilmiştir.
- Lineer Regresyon: Sınıflandırma amacıyla kullanıldığında %48.28 doğruluk ve 0.41 F1-skoru ile en düşük başarıyı sağlamıştır. Doğrusal bir modelin, poker eli gibi kategorik ve karmaşık ilişkiler içeren bir sınıflandırma probleminde etkili olamayacağı bu sonuçla doğrulanmıştır.

Tartışma:


Bu çalışmada elde edilen sonuçlar, poker eli sınıflandırması gibi karmaşık ve dengesiz veri setleri için algoritma seçiminin kritik önem taşıdığını vurgulamaktadır. Rastgele Orman'ın üstün performansı, topluluk öğrenme yöntemlerinin bu tür zorluklarla başa çıkmadaki gücünü göstermektedir. Ağaç tabanlı diğer model olan Karar Ağacı, optimizasyonla iyileşse de Rastgele Orman'ın sağlamlığına ulaşamamıştır.

Öte yandan, daha basit varsayımlara dayanan modeller (Naive Bayes'in bağımsızlık varsayımı, Lojistik ve Lineer Regresyon'un doğrusallık varsayımı) bu veri setinde belirgin şekilde başarısız olmuştur. Bu durum, poker eli kombinasyonlarındaki özellikler arası etkileşimlerin ve doğrusal olmayan örüntülerin bu modeller tarafından yakalanamadığını göstermektedir. KNN'nin performansı da, muhtemelen veri yoğunluğu ve boyutsallık gibi faktörler nedeniyle sınırlı kalmıştır.


Sonuç olarak, poker eli sınıflandırması görevi için Rastgele Orman algoritmasının en uygun seçenek olduğu, Karar Ağacı'nın ise optimizasyonla kabul edilebilir ancak daha düşük bir performans sunduğu görülmüştür. Diğer test edilen algoritmalar (Naive Bayes, Lojistik Regresyon, Lineer Regresyon, KNN) bu spesifik problem için yetersiz kalmıştır. Bu bulgular, benzer özelliklere sahip (karmaşıklık, sınıf dengesizliği) diğer sınıflandırma problemlerinde de model seçimi için yol gösterici olabilir.

	Doğruluk Oranları		
	Test Verisi (1.000.00 örnek)	Eğitim Verisi (25.000 Örnek)	İyileştirilmiş Eğitim Verisi (25.000 örnek)
<i>Random Forest</i>	0.75	0.61	0.92
<i>Karar Ağacı</i>	0.58	0.49	0.67
<i>K-NN</i>	0.54	0.50	0.56
<i>Naive Bayes</i>	0.50	0.51	0.54
<i>Lojistik Regresyon</i>	0.50	0.51	0.51
<i>Lineer Regresyon</i>	0.42	0.48	-


Modellerin farklı örnek sayısınca bulunan doğruluk oranları grafiklendirilmiş, ayrıca; random forest ve karar ağacı algoritmaları ile eğitilmiş olan modellerin optimizasyondan öncesi-optimizasyondan sonrası karşılaştırması ROC eğrisi ve karışıklık matrisleri ile görselleştirilmiştir.



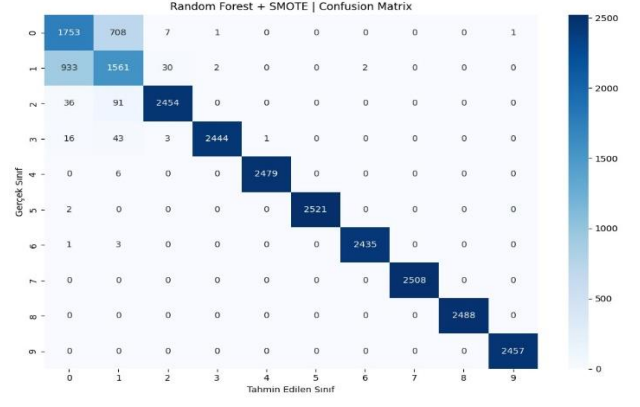

1.000.000 Örnekli (Testing) Veri Seti Doğruluk Oranı Tablosu



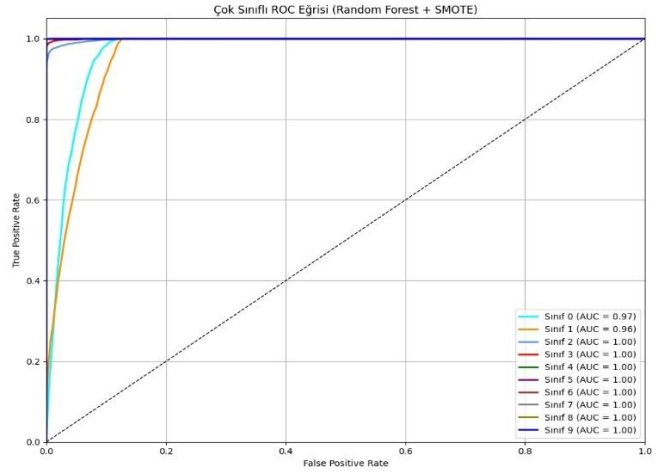
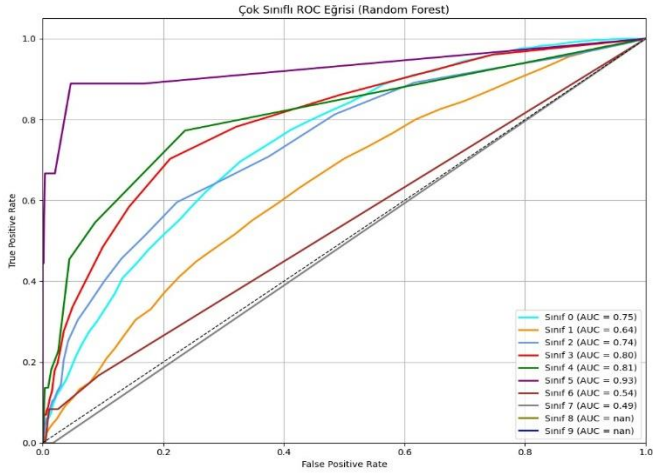
25.000 Örnekli (Training) Veri Seti Doğruluk Oranı Tablosu





25.000 Örnekli (Training) Optimize Edilmiş Veri Seti Doğruluk Oranı Tablosu



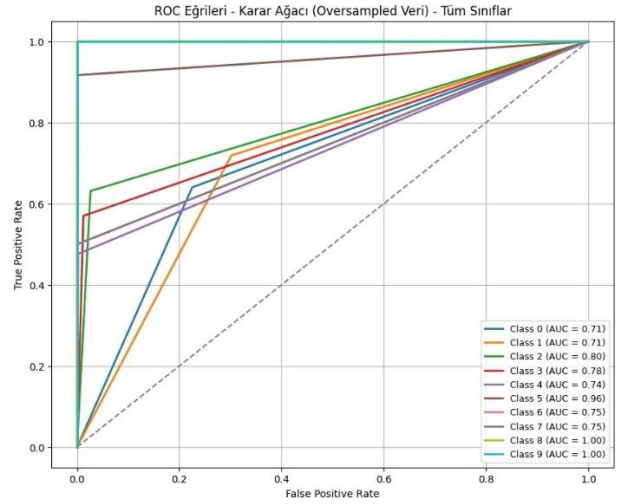
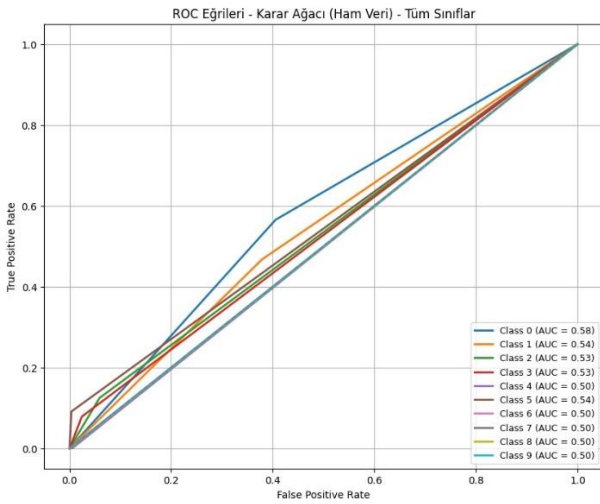
Random Forest Algoritmasının Optimizasyon Sonrası Karışıklık Matrisi Karşılaştırması



Random Forest Algoritmasının Optimizasyon Sonrası ROC Eğrisi Karşılaştırması



Karar Ağacı Algoritmasının Optimizasyon Sonrası Karışıklık Matrisi Karşılaştırması



Karar Ağacı Algoritmasının Optimizasyon Sonrası ROC Eğrisi Karşılaştırması

5. Kaynakça

1. "Poker Hand Classification using Machine Learning" - R. P. Lippmann, et al.
2. "Using Machine Learning Algorithms to Improve Poker Strategies" - J. M. McCarty et al.
3. "Poker AI and Machine Learning: An Overview of Techniques" - A. P. V. Branca et al.
4. UCI Machine Learning Repository - Poker Hand Dataset
[Link: <https://archive.ics.uci.edu/ml/datasets/Poker+Hand>]
5. "Introduction to Game Theory" - Martin J. Osborne
[Link: <https://global.oup.com/academic/product/introduction-to-game-theory-9780195128956>]
6. "Decision Trees and Random Forests: A Visual Introduction for Beginners" - Chris Smith
7. "Pattern Recognition and Machine Learning" - Christopher M. Bishop
8. "The Mathematics of Poker" - Bill Chen and Jerrod Ankenman
9. "Applied Predictive Modeling" - Max Kuhn, Kjell Johnson
10. "Machine Learning for Poker" - Russell Crowder
11. Google Scholar - Poker Algorithms
[Link: <https://scholar.google.com/>]
12. "Random Forests: A Comprehensive Tutorial in Machine Learning" - DataCamp
[Link: <https://www.datacamp.com/community/tutorials/random-forest-classifier-python>]
13. Stack Overflow - Poker Hand Machine Learning
[Link: <https://stackoverflow.com/questions/tagged/poker-machine-learning>]
14. "Deep Learning for Poker Players" - David S. W. Lee
15. Wikipedia - Poker
[Link: <https://en.wikipedia.org/wiki/Poker>]